



PROPOSAL PROYEK AKHIR

PENGEMBANGAN SISTEM KLASIFIKASI SKETSA BERBASIS CNN MOBILENET DENGAN CONFIDENCE SCORE DAN CLUSTERING POLA KEPUTUSAN PADA SISTEM LITERASI KECERDASAN BUATAN UNTUK SISWA SMP'

Muhammad Dias Al Izzat
NRP.5323600006

DOSEN PEMBIMBING

Dr. Tri Budi Santoso, S.T., M.T
NIP. 197001051995021001

Dr. Ing.-Hestiasari Rante, S.T., M.Sc.
NIP. 197607152008122001

**PROGRAM STUDI SARJANA TERAPAN
TEKNOLOGI REKAYASA MULTIMEDIA
JURUSAN TEKNOLOGI MULTIMEDIA KREATIF
POLITEKNIK ELEKTRONIKA NEGERI SURABAYA
2026**

Halaman ini sengaja dikosongkan

HALAMAN PENGESAHAN

SISTEM LITERASI KECERDASAN BUATAN SISWA SMP (PENGEMBANGAN SISTEM KLASIFIKASI SKETSA CNN MOBILENET DENGAN CONFIDENCE SCORE EKSPLISIT DAN CLUSTERING POLA KEPUTUSAN)

Oleh:

Muhammad Dias Al Izzat
NRP 5323600006

Disetujui dan disahkan pada 2 Juli 2026 oleh:

Tim Penguji Proyek Akhir

1.



Rendra Suprobo Aji, S.T., M.T.
NIP. 198705212023211023

2.



Dr. Muhammad Agus Zainuddin, S.T., M.T.
NIP. 197808122008011029

Dosen Pembimbing

1.



Dr. Tri Budi Santoso, S.T., M.T.
NIP. 197001051995021001

2.



Dr.-Ing. Hestiasari Rante, S.T., M.Sc.
NIP. 197607152008122001

Mengetahui,
Koordinator Program Studi
Sarjana Terapan Teknologi Rekayasa Multimedia



Ashafidz Fauzan Dianta, S.ST., M.T.
NIP. 198703112020121002

Halaman ini sengaja dikosongkan

ABSTRAK

Kecerdasan buatan (AI) telah menjadi bagian tak terpisahkan dari kehidupan sehari-hari, termasuk bagi siswa Sekolah Menengah Pertama (SMP). Namun, paparan terhadap AI tanpa scaffolding yang tepat berisiko menimbulkan automation bias. Penelitian ini mengusulkan Sketchbook Universe, sebuah simulasi interaktif berbasis Human-in-the-Loop (HITL) untuk memfasilitasi interaksi reflektif siswa SMP terhadap output AI. Bagian backend sistem ini mencakup klasifikasi sketsa menggunakan Convolutional Neural Network (CNN) MobileNet yang dideploy secara client-side melalui TensorFlow.js, REST API berbasis Node.js dan Express untuk data logging ke SQLite, serta analisis pola perilaku siswa menggunakan K-Means clustering. Sistem menghasilkan tiga hingga lima cluster perilaku (Trust Acceptor, Critical Evaluator, Uncertain Explorer) yang dapat dimanfaatkan oleh guru untuk evaluasi pembelajaran. Penelitian ini menggunakan metode Mixed Methods dengan pendekatan Research and Development (R&D), metode pengembangan SDLC Waterfall, dan teknik analisis Fishbone 6M. Pengujian dilakukan menggunakan akurasi model CNN dan System Usability Scale (SUS) bersama rekan penelitian. Scope penelitian mencakup backend, CNN, K-Means, REST API, dan admin dashboard, sementara frontend, UI/UX, dan maskot ditangani oleh rekan penelitian sebagai proyek kelompok.

Kata Kunci: Klasifikasi Sketsa, CNN MobileNet, TensorFlow.js, K-Means Clustering, Human-in-the-Loop, Data Logging

ABSTRACT

Artificial Intelligence (AI) has become an inseparable part of daily life, including for junior high school students. However, exposure to AI without proper scaffolding risks automation bias. This research proposes Sketchbook Universe, an interactive simulation based on Human-in-the-Loop (HITL) to facilitate reflective interaction of junior high school students with AI output. The backend part of this system includes sketch classification using Convolutional Neural Network (CNN) MobileNet deployed client-side via TensorFlow.js, REST API based on Node.js and Express for data logging to SQLite, and student behavioral pattern analysis using K-Means clustering. The system produces three to five behavioral clusters (Trust Acceptor, Critical Evaluator, Uncertain Explorer) that can be utilized by teachers for learning evaluation. The research uses Mixed Methods with Research and Development (R&D) approach, SDLC Waterfall development method, and Fishbone 6M analysis technique. Testing is conducted using CNN model accuracy and System Usability Scale (SUS) together with the research partner. The research scope covers backend, CNN, K-Means, REST API, and admin dashboard, while frontend, UI/UX, and mascot are handled by the research partner as a group project.

Keywords: Sketch Classification, CNN MobileNet, TensorFlow.js, K-Means Clustering, Human-in-the-Loop, Data Logging

DAFTAR ISI

ABSTRAK	i
ABSTRACT	ii
DAFTAR ISI.....	iii
DAFTAR GAMBAR.....	v
DAFTAR TABEL.....	vi
BAB I.....	1
PENDAHULUAN.....	1
1.1 LATAR BELAKANG	1
1.2 PERMASALAHAN.....	2
1.3 BATASAN MASALAH	2
1.4 TUJUAN	3
1.5 MANFAAT	3
1.6 SISTEMATIKA PENULISAN	4
BAB II	1
KAJIAN PUSTAKA	1
2.1 DESKRIPSI PERMASALAHAN.....	1
2.2 TEORI PENUNJANG	2
2.2.1 Literasi Kecerdasan Buatan.....	2
2.2.2 Human-in-the-Loop pada Sistem Klasifikasi.....	2
2.2.3 Klasifikasi Sketsa	3
2.2.4 Convolutional Neural Network dan MobileNet.....	3
2.2.5 TensorFlow.js dan Client-Side Inference.....	4
2.2.6 Confidence Score dan Data Logging	4
2.2.7 K-Means Clustering	5
2.3 PENELITIAN TERKAIT	5
2.3.1 Deep Learning for Free-Hand Sketch Recognition.....	5
2.3.2 Front-End Deep Learning Web Applications	6
2.3.3 Confidence Visualization	6
2.3.4 K-Means untuk Pola Belajar	7
2.3.5 Perbandingan Arsitektur MobileNetV2 dan MobileNetV3	7
2.3.6 State of The Art.....	8
BAB III.....	1
DESKRIPSI SISTEM	1
3.1 DESKRIPSI SOLUSI.....	1
3.2 METODOLOGI PENELITIAN.....	1
3.2.1 Jenis Penelitian.....	2
3.2.2 Analisis Masalah	2
3.2.3 Teknik Pengumpulan dan Analisis Data	2
3.3 DESAIN SISTEM.....	3
3.3.1 Pemilihan Model CNN.....	3
3.3.2 Desain Sistem Global	8
3.3.3 User Flow	9
3.3.4 Use Case.....	13
3.3.5 Alur Backend	13

3.3.6 Perancangan K-Means Clustering.....	14
3.3.7 Perancangan Technology Stack	14
3.4 PEMBAGIAN TUGAS.....	16
3.5 JADWAL PENELITIAN	17
DAFTAR PUSTAKA	20

DAFTAR GAMBAR

Gambar 3. 1 Desain Sistem Global.....	9
Gambar 3. 2 Userflow Fase 1.....	10
Gambar 3. 3 UserFlow Fase 2.....	11
Gambar 3. 4 UserFlow Fase 3.....	12
Gambar 3. 5 Use Case.....	13

DAFTAR TABEL

Tabel 2. 1 Perbandingan Hasil Pengujian MobileNetV2 dan MobileNetV3	8
Tabel 2. 2 Rangkuman Cakupan Penelitian Terkait.....	9
Tabel 3. 1 Perbandingan Akurasi Enam Model CNN pada Data Gambar Tangan Siswa	3
Tabel 3. 2 Perbandingan Resmi MobileNetV1, V2, dan V3 pada Benchmark ImageNet.....	5
Tabel 3. 3 Hasil Pengujian MobileNetV3 pada Dataset Kecil (Klasifikasi American Sign Language).....	6
Tabel 3. 4 Perbandingan Batch Time dan Epoch Time pada Dataset MNIST (28×28 piksel)	8
Tabel 3. 5 Feature Engineering untuk K-Means Clustering	14
Tabel 3. 6 Technology Stack.....	15
Tabel 3. 7 Pembagian Tugas per Komponen Sistem	16
Tabel 3. 8 Jadwal Penelitian Sinkron 17 Kegiatan 12 Bulan.....	18

BAB I

PENDAHULUAN

1.1 LATAR BELAKANG

Perkembangan kecerdasan buatan (Artificial Intelligence/AI) mendorong kebutuhan literasi teknologi yang tidak hanya berfokus pada kemampuan menggunakan aplikasi digital, tetapi juga memahami cara kerja sistem cerdas. Dalam konteks pendidikan, pemahaman ini penting agar siswa tidak menganggap keluaran AI sebagai jawaban mutlak, melainkan sebagai hasil prediksi yang perlu dievaluasi secara kritis.

Literasi AI mencakup kemampuan memahami, menggunakan, mengevaluasi, serta mempertimbangkan dampak penggunaan sistem berbasis AI [1], [2]. Salah satu pendekatan yang dapat digunakan untuk memperkenalkan konsep tersebut adalah melalui klasifikasi sketsa, karena siswa dapat melihat secara langsung hubungan antara input gambar, hasil prediksi, dan tingkat keyakinan model.

Pada penelitian ini, sistem literasi AI diwujudkan dalam bentuk simulasi klasifikasi sketsa. Siswa menggambar suatu objek, kemudian sistem melakukan prediksi dan menampilkan Top-3 prediction beserta confidence score. Penyajian ini mendukung konsep Explainable Artificial Intelligence (XAI), sehingga pengguna dapat memahami bahwa model memiliki tingkat keyakinan yang berbeda pada setiap prediksi [3].

Dari sisi teknis, sistem menggunakan Convolutional Neural Network (CNN) berbasis MobileNet untuk klasifikasi sketsa. Arsitektur ini dipilih karena mampu melakukan ekstraksi fitur visual dengan efisien dan cocok untuk inferensi ringan pada perangkat pengguna [6]. Model dijalankan pada browser menggunakan TensorFlow.js, sehingga proses inferensi dapat dilakukan secara client-side tanpa server machine learning khusus [7].

Selain klasifikasi, sistem juga mencatat data interaksi pengguna seperti confidence score, keputusan pengguna, durasi pengambilan keputusan, dan retry

count. Data ini dianalisis menggunakan K-Means clustering untuk mengidentifikasi pola perilaku siswa terhadap keluaran probabilistik AI. Penelitian ini berfokus pada pengembangan pipeline klasifikasi sketsa, client-side inference, data logging, serta analisis pola keputusan pengguna berbasis clustering..

1.2 PERMASALAHAN

Sistem literasi kecerdasan buatan membutuhkan model klasifikasi yang mampu mengenali sketsa siswa dan menyajikan keluaran dalam bentuk yang dapat dievaluasi. Apabila sistem hanya menampilkan satu label akhir, pengguna berpotensi memahami hasil model sebagai jawaban mutlak. Oleh karena itu, diperlukan sistem klasifikasi sketsa berbasis CNN MobileNet yang dapat menghasilkan *Top-3 prediction* dan *confidence score*, menjalankan inferensi pada sisi klien menggunakan TensorFlow.js, serta mencatat *log* keputusan pengguna untuk dianalisis sebagai pola perilaku terhadap keluaran probabilistik sistem.

1.3 BATASAN MASALAH

1. Penelitian ini dibatasi pada pengembangan model klasifikasi sketsa berbasis CNN MobileNet untuk mendukung sistem literasi kecerdasan buatan bagi siswa SMP kelas 7 sampai 9.
2. Model dijalankan menggunakan TensorFlow.js pada sisi klien, sehingga tidak menggunakan *backend* kecerdasan buatan, *server machine learning*, atau inferensi berbasis *cloud*.
3. Dataset yang digunakan dibatasi pada subset kategori sketsa yang relevan dengan kebutuhan simulasi, yaitu kategori yang dapat dipetakan menjadi Solid, Danger, atau Decorative.
4. Sistem tidak melakukan pelatihan ulang model secara otomatis dari input pengguna dan tidak bersifat adaptif terhadap keputusan pengguna secara *real-time*.
5. Server hanya digunakan untuk *REST API logging* dan penyimpanan data interaksi menggunakan SQLite.

6. Analisis *K-Means clustering* difokuskan pada pola keputusan pengguna berdasarkan *log* interaksi dan tidak digunakan untuk menyimpulkan peningkatan kemampuan siswa melalui *pre-test* dan *post-test*.

1.4 TUJUAN

Penelitian ini bertujuan untuk mengembangkan sistem klasifikasi sketsa berbasis CNN MobileNet yang dapat mendukung sistem literasi kecerdasan buatan siswa SMP. Tujuan khusus penelitian ini adalah menghasilkan keluaran klasifikasi berupa *Top-3 prediction* dan *confidence score* yang dapat digunakan pada mekanisme *Human-in-the-Loop*. Penelitian ini juga bertujuan merancang *pipeline client-side inference* menggunakan TensorFlow.js, sistem *logging* berbasis *REST API* dan SQLite, serta analisis pola keputusan menggunakan *K-Means clustering*.

Secara keseluruhan, penelitian ini diarahkan untuk membantu siswa SMP membangun literasi kecerdasan buatan melalui pengalaman langsung mengevaluasi keluaran AI yang bersifat probabilistik, sehingga siswa tidak hanya menerima hasil AI secara pasif, melainkan terlatih untuk berpikir kritis terhadap keluaran sistem cerdas yang mereka temui dalam kehidupan sehari-hari.

1.5 MANFAAT

1. Bagi siswa, sistem ini dapat membantu memperlihatkan bahwa hasil kecerdasan buatan bersifat prediktif dan memiliki tingkat keyakinan tertentu.
2. Bagi guru atau sekolah, sistem ini dapat menjadi media pendukung pembelajaran literasi kecerdasan buatan berbasis aktivitas interaktif.
3. Bagi pengembang sistem, penelitian ini memberikan rancangan *pipeline* klasifikasi sketsa *client-side* yang dapat diintegrasikan dengan simulasi web.
4. Bagi peneliti, data *log* dan hasil *clustering* dapat menjadi dasar analisis pola keputusan pengguna terhadap keluaran probabilistik sistem.

1.6 SISTEMATIKA PENULISAN

BAB I Pendahuluan: membahas latar belakang, permasalahan, batasan masalah, tujuan, manfaat, dan sistematika penulisan. BAB II Kajian Pustaka: membahas deskripsi permasalahan, teori penunjang, penelitian terkait, dan *state of the art*. BAB III Deskripsi Sistem: membahas deskripsi solusi, metodologi penelitian, desain sistem, rancangan pengujian, dan jadwal penelitian.

Halaman ini sengaja dikosongkan

BAB II

KAJIAN PUSTAKA

Bab ini menyajikan kajian pustaka yang menjadi landasan teoretis bagi perancangan komponen *backend*, klasifikasi, pencatatan data, dan analisis pada sistem *Sketchbook Universe*. Kajian dimulai dari deskripsi permasalahan yang menjelaskan mengapa klasifikasi berlabel tunggal belum memadai secara pedagogis, mengapa *confidence score* harus divisualisasikan, dan mengapa pencatatan interaksi harus terstruktur untuk keperluan analisis. Dilanjutkan dengan teori penunjang yang mendasari setiap keputusan teknis mulai dari literasi kecerdasan buatan, *Human-in-the-Loop*, klasifikasi sketsa, arsitektur CNN dan MobileNet, inferensi *client-side* dengan TensorFlow.js, *confidence score*, *data logging*, hingga *K-Means clustering* serta ditutup dengan penelitian terkait dan analisis *state of the art* yang memosisikan kontribusi teknis proyek ini di antara kajian-kajian sebelumnya. Pembahasan teori pada bab ini bersifat ringkas; rincian implementasi teknis akan diuraikan pada Bab III.

2.1 DESKRIPSI PERMASALAHAN

Permasalahan utama dalam proyek ini adalah belum adanya media interaktif yang membantu siswa SMP kelas 7-9 untuk mengevaluasi keluaran kecerdasan buatan secara kritis melalui simulasi klasifikasi sketsa. Sebagian besar sistem klasifikasi gambar hanya menampilkan satu label prediksi akhir tanpa menunjukkan distribusi probabilitas atau tingkat keyakinan model. Kondisi ini membuat siswa cenderung menerima hasil AI secara langsung tanpa memahami bahwa keluaran tersebut bersifat prediktif dan memiliki tingkat ketidakpastian tertentu, yang dapat memicu automation bias [1], [4].

Untuk mengatasi hal tersebut, diperlukan sistem yang tidak hanya mampu melakukan klasifikasi sketsa, tetapi juga menampilkan Top-3 prediction beserta *confidence score* agar proses pengambilan keputusan AI lebih transparan [3]. Selain

itu, diperlukan mekanisme data logging untuk mencatat interaksi siswa seperti hasil prediksi, confidence score, keputusan pengguna, dan waktu respons. Data ini kemudian dianalisis menggunakan K-Means clustering untuk mengidentifikasi pola perilaku siswa terhadap keluaran AI [5], [10].

2.2 TEORI PENUNJANG

Bagian ini membahas teori-teori yang mendasari perancangan komponen teknis pada proyek Sketchbook Universe. Rincian implementasi teknis diuraikan pada Bab III.

2.2.1 Literasi Kecerdasan Buatan

Literasi kecerdasan buatan didefinisikan oleh Ng et al. [1] sebagai seperangkat kompetensi untuk memahami, menggunakan, mengevaluasi, dan merefleksikan teknologi AI dalam kehidupan sehari-hari. Kerangka ini mencakup empat dimensi: know and understand AI, use and apply AI, evaluate and create AI, serta AI ethics. Dimensi evaluasi menjadi relevan dalam proyek ini karena mencakup kemampuan menilai keluaran AI secara kritis termasuk memahami bahwa confidence score merepresentasikan tingkat keyakinan model, bukan kebenaran absolut.

Dalam konteks K-12, Casal-Otero et al. [2] menemukan bahwa strategi literasi AI yang efektif harus mempertimbangkan tahap perkembangan kognitif peserta didik. Siswa SMP belum sepenuhnya mampu berpikir abstrak tentang konsep probabilistik, sehingga diperlukan pendekatan yang sesuai usia untuk membuat konsep tersebut dapat diamati secara langsung. Relevansi terhadap proyek ini terletak pada mekanisme visualisasi Top-3 confidence score: siswa dapat mengamati bahwa model mendistribusikan keyakinannya ke beberapa kelas, bukan menunjuk satu jawaban dengan kepastian penuh.

2.2.2 Human-in-the-Loop pada Sistem Klasifikasi

Human-in-the-Loop (HITL) adalah paradigma di mana manusia berpartisipasi aktif dalam alur keputusan sistem otomatis. Mosqueira-Rey et al. [4]

mengidentifikasi bahwa HITL penting terutama untuk mencegah automation bias kecenderungan menerima keluaran AI secara tidak kritis. Memarian & Doleck [5] menambahkan bahwa efektivitas HITL bergantung pada kualitas informasi yang disajikan kepada pengguna; tanpa konteks yang memadai, manusia cenderung menjadi rubber stamp yang sekadar menyetujui keputusan mesin.

Dalam proyek Sketchbook Universe, HITL diimplementasikan dengan prinsip yang jelas: sistem menyajikan Top-3 confidence score kepada siswa, kemudian siswa memutuskan apakah menyetujui atau menolak prediksi AI. Keputusan dicatat sebagai log untuk analisis pola perilaku, namun tidak digunakan untuk melatih ulang model-model MobileNet bersifat statis.

2.2.3 Klasifikasi Sketsa

Klasifikasi sketsa adalah tugas mengkategorikan gambar sketsa tangan ke dalam kelas yang telah ditentukan. Xu et al. [6] mengidentifikasi karakteristik khas sketsa dibanding foto: bersifat sparse (hanya garis esensial tanpa warna atau tekstur), memiliki tingkat abstraksi bervariasi, dan seringkali ambigu. Tantangan ini semakin kompleks pada siswa SMP akibat variasi gaya menggambar, sehingga model cenderung mendistribusikan probabilitas ke beberapa kelas sekaligus kondisi yang justru menguntungkan secara pedagogis karena memperlihatkan ketidakpastian model.

Kategori sketsa dalam sistem ini terbagi menjadi tiga subset: Solid (benda padat), Danger (benda berbahaya), dan Decorative (benda dekoratif), yang masing-masing memiliki konsekuensi berbeda dalam simulasi.

2.2.4 Convolutional Neural Network dan MobileNet

Convolutional Neural Network (CNN) adalah arsitektur jaringan saraf tiruan untuk pemrosesan data berbasis grid seperti gambar. CNN mengekstraksi fitur hierarkis secara otomatis lapisan awal menangkap tepi dan tekstur, lapisan lebih dalam menangkap bentuk dan struktur tanpa memerlukan feature engineering manual [6].

MobileNet adalah varian CNN ringan yang dikembangkan Google untuk perangkat dengan sumber daya terbatas. Efisiensinya dicapai melalui depthwise separable convolution dan dua hyperparameter (width multiplier α dan resolution multiplier ρ) yang mengatur trade-off antara akurasi dan efisiensi. Dalam proyek ini, MobileNet dijalankan di sisi klien melalui TensorFlow.js dengan pendekatan transfer learning dari ImageNet, sehingga mengurangi kebutuhan data latih dan waktu pelatihan.

2.2.5 TensorFlow.js dan Client-Side Inference

TensorFlow.js adalah library open-source yang memungkinkan inferensi model machine learning langsung di browser tanpa instalasi tambahan. Library ini mendukung dua backend: WebGL (memanfaatkan GPU) dan CPU sebagai fallback [8]. Goh et al. [7] mengidentifikasi pertimbangan kritis dalam deployment: ukuran model, latensi inferensi, dan kompatibilitas browser.

Dalam proyek ini, seluruh inferensi dilaksanakan di sisi klien (browser siswa). Server hanya berperan sebagai REST API untuk pencatatan log ke database SQLite, bukan untuk menjalankan inferensi. Pendekatan ini mengurangi latensi jaringan dan menjaga privasi data sketsa siswa, sekaligus menjadikan pemilihan model ringan seperti MobileNet sebagai keharusan arsitektural

2.2.6 Confidence Score dan Data Logging

Confidence score adalah nilai numerik yang merepresentasikan tingkat keyakinan model terhadap setiap kelas, dihasilkan melalui fungsi softmax. Karran et al. [9] menemukan bahwa visualisasi distribusi confidence di beberapa kelas seperti bar chart Top-3 membantu pengguna mengevaluasi keluaran AI secara lebih bermakna dibanding hanya menampilkan prediksi terbaik.

Data logging dirancang untuk menangkap konteks lengkap setiap keputusan siswa, mencakup: sketch_id, top3_predictions, top3_confidences, user_decision, response_time, session_id, dan timestamp. Salah satu metrik turunan adalah confidence gap selisih antara confidence tertinggi dan kedua tertinggi yang

digunakan untuk menganalisis bagaimana siswa merespons situasi ketika model ragu versus ketika model yakin [5].

2.2.7 K-Means Clustering

K-Means clustering adalah algoritma unsupervised learning yang mengelompokkan data ke dalam k kelompok berdasarkan kemiripan fitur secara iteratif. Pansri et al. [10] dan Alzahrani et al. [11] menunjukkan bahwa K-Means efektif untuk mengidentifikasi pola perilaku belajar siswa dari data interaksi pada sistem pembelajaran.

Dalam proyek ini, K-Means diterapkan untuk menganalisis pola keputusan siswa berdasarkan fitur: rasio persetujuan terhadap prediksi AI, rata-rata confidence gap, dan rata-rata response time. Hasil pengelompokan diinterpretasikan ke dalam tiga profil: Trust Acceptor, Critical Evaluator, dan Uncertain Explorer. Perlu ditekankan bahwa profil ini bersifat interpretif bukan diagnostik atau penilaian kompetensi melainkan label yang didasarkan pada pengamatan pola data.

2.3 PENELITIAN TERKAIT

Bagian ini membahas penelitian-penelitian terkait yang menjadi referensi dalam perancangan komponen teknis proyek Sketchbook Universe, dianalisis dari segi relevansi dan kontribusinya terhadap aspek-aspek spesifik yang dikembangkan.

2.3.1 Deep Learning for Free-Hand Sketch Recognition

Xu et al. [6] menyajikan survei komprehensif mengenai penerapan deep learning untuk pengenalan sketsa tangan bebas, mencakup evolusi dari metode berbasis hand-crafted features hingga pendekatan CNN end-to-end. Temuan utama mereka adalah bahwa arsitektur seperti VGG dan ResNet tidak selalu optimal untuk sketsa, karena data sketsa bersifat sparse dan biner sehingga representasi fitur dari gambar fotografis tidak sepenuhnya transferabel. Temuan ini mendukung keputusan menampilkan Top-3 confidence score, karena ambiguitas inheren sketsa membuat model jarang memberikan prediksi dengan confidence tinggi pada satu

kelas. Teknik data augmentation yang mereka identifikasi juga menjadi referensi pra-pemrosesan data latih pada model yang digunakan dalam proyek ini.

Sebagai perbandingan, Li et al. [27] melalui arsitektur Sketch-R2CNN memperkenalkan pendekatan RNN-rasterization-CNN untuk sketsa vektor, yang menjadi alternatif arsitektur yang diperbandingkan dengan pendekatan CNN-only yang dipilih pada proyek ini.

2.3.2 Front-End Deep Learning Web Applications

Goh, Ho & Abas [7] mengkaji penerapan deep learning pada front-end web application dengan fokus pada tantangan deployment. Mereka menemukan bahwa pendekatan client-side deployment memiliki keunggulan dalam hal latensi, privasi data, dan aksesibilitas. Secara spesifik, MobileNetV2 dengan width multiplier 0,5 atau 0,75 memberikan keseimbangan terbaik antara akurasi dan efisiensi, dengan waktu inferensi 30-100 ms pada perangkat menengah dan ukuran model di bawah 5 MB.

Smilkov et al. [8] sebagai pengembang TensorFlow.js menjelaskan arsitektur library yang mendukung akselerasi WebGL dan fallback CPU. Kedua penelitian ini menjadi landasan teknis keputusan arsitektural untuk menggunakan MobileNet yang dijalankan di sisi klien pada proyek ini.

2.3.3 Confidence Visualization

Karran, Demazure & Hudelot [9] mengkaji desain visualisasi confidence untuk membantu pengguna menilai keluaran sistem AI. Mereka mengidentifikasi bahwa efektivitas visualisasi bergantung pada tiga faktor: granularity (apakah menampilkan satu nilai atau distribusi lengkap), comparability (apakah memungkinkan perbandingan antar alternatif), dan contextual framing (apakah menyertakan konteks interpretasi). Visualisasi yang menampilkan distribusi confidence di beberapa alternatif, seperti bar chart Top-N, terbukti lebih efektif dalam memfasilitasi evaluasi kritis dibanding menampilkan satu angka saja.

Temuan ini memberikan dukungan empiris atas keputusan menampilkan Top-3 confidence score dalam proyek ini. Prinsip comparability menegaskan

bahwa siswa perlu membandingkan beberapa alternatif untuk dapat mengevaluasi keluaran AI secara bermakna, yang merupakan esensi dari mekanisme HITL dalam sistem ini.

2.3.4 K-Means untuk Pola Belajar

Pansri et al. [10] menerapkan K-Means untuk menganalisis pola perilaku belajar siswa dari data interaksi pada learning management system dan menghasilkan empat profil perilaku: active learners, sporadic learners, struggling learners, dan disengaged learners. Mereka menekankan bahwa profil ini bersifat deskriptif, bukan diagnostik. Alzahrani et al. [11] menggunakan pendekatan serupa dan menemukan bahwa kombinasi elbow method dengan silhouette score menghasilkan pengelompokan yang paling stabil dan dapat diinterpretasikan.

Relevansi kedua penelitian ini terletak pada metodologi penerapan K-Means untuk analisis pola perilaku dalam konteks pendidikan. Perbedaan utamanya adalah kedua penelitian tersebut menganalisis perilaku belajar umum, sementara proyek ini berfokus pada pola keputusan spesifik terhadap keluaran AI. Hal ini menghasilkan profil yang secara konseptual berbeda: Trust Acceptor, Critical Evaluator, dan Uncertain Explorer merupakan profil keputusan terhadap AI, bukan profil gaya belajar umum.

2.3.5 Perbandingan Arsitektur MobileNetV2 dan MobileNetV3

Wardhana dan Nugroho [30] membandingkan performa arsitektur MobileNetV2 dan MobileNetV3 pada tugas klasifikasi citra tiga jenis jeruk (lemon, jeruk manis, dan jeruk nipis) menggunakan dataset sebanyak 1.500 gambar. Kedua model dilatih dengan kondisi yang identik meliputi optimizer Adam, learning rate 0,001, serta empat skenario epoch (5, 10, 15, dan 20) untuk memastikan perbandingan yang adil. Hasil pengujian menunjukkan bahwa MobileNetV2 memperoleh rata-rata akurasi 99,33%, jauh melampaui MobileNetV3 yang hanya mencapai 42,97%. Selain unggul dalam akurasi, MobileNetV2 juga dilaporkan lebih efisien dalam penggunaan sumber daya komputasi. Tabel 2.1 merangkum perbandingan hasil pengujian kedua arsitektur tersebut.

Tabel 2. 1 Perbandingan Hasil Pengujian MobileNetV2 dan MobileNetV3

Metrik	MobileNetV2	MobileNetV3
Akurasi Pelatihan	99,33%	42,97%
Akurasi Pengujian	99,41%	47,40%
Precision	79,77%	27,83%
Recall	34,26%	31,45%
F1-Score	34,53%	19,88%

Sumber: Wardhana dan Nugroho (2025) [30].

Penurunan performa MobileNetV3 dikaitkan dengan kompleksitas tambahan pada arsitekturnya, yaitu squeeze-and-excitation module dan fungsi aktivasi h-swish, yang cenderung menyebabkan model lebih rentan mengalami overfitting ketika dilatih pada dataset berskala kecil hingga menengah. Sebaliknya, struktur inverted residual dengan bottleneck pada MobileNetV2 memungkinkan model memproses informasi secara lebih efisien dengan jumlah parameter yang lebih sedikit.

Temuan ini relevan dengan proyek Sketchbook Universe meskipun berbeda domain (klasifikasi citra buah dibanding klasifikasi sketsa), karena kedua sistem sama-sama menggunakan MobileNet sebagai backbone dan dilatih pada dataset berskala terbatas. Bukti empiris pada domain lain ini memperkuat pertimbangan bahwa varian arsitektur yang lebih kompleks tidak selalu memberikan keunggulan performa pada skala data yang terbatas, sebagaimana dijadikan salah satu dasar pemilihan MobileNetV2 pada perancangan model CNN di Bab III.

2.3.6 State of The Art

Berdasarkan kajian terhadap penelitian-penelitian terkait, dapat diidentifikasi posisi *state of the art* dan celah penelitian yang diisi oleh proyek *Sketchbook Universe*. Tabel 2.2 merangkum cakupan masing-masing penelitian terkait.

Tabel 2. 2 Rangkuman Cakupan Penelitian Terkait

Penelitian	Klasifikasi Sketsa	Client-Side Infer.	Conf. Vis.	HITL Logging	K-Means Analisis	Integrasi Sistem
Xu et al. [6]	✓	–	–	–	–	–
Goh et al. [7]	–	✓	–	–	–	–
Smilkov et al. [8]	–	✓	–	–	–	–
Karran et al. [9]	–	–	✓	–	–	–
Pansri et al. [10]	–	–	–	–	✓	–
Alzahrani et al. [11]	–	–	–	–	✓	–
Li et al. [27]	✓	–	–	–	–	–
Proyek ini	✓	✓	✓	✓	✓	✓

Dari Tabel 2.2 terlihat bahwa setiap penelitian terkait memberikan kontribusi pada satu aspek spesifik. Namun, tidak ada satu pun yang mengintegrasikan seluruh komponen klasifikasi sketsa, inferensi client-side, visualisasi confidence, mekanisme HITL dengan logging terstruktur, dan analisis K-Means clustering dalam satu sistem yang koheren. Proyek ini mengisi celah tersebut.

Halaman ini sengaja dikosongkan

BAB III

DESKRIPSI SISTEM

Bab ini menguraikan deskripsi solusi, metodologi penelitian, gambaran desain sistem, pembagian tugas, dan jadwal penelitian. Scope yang dibahas pada bab ini adalah bagian penulis, yaitu CNN MobileNet, Backend REST API, SQLite, K-Means Clustering, dan Admin Dashboard. Bagian Frontend, UI/UX, Probe UI, Animasi Momo, dan Level Design merupakan tanggung jawab rekan penelitian.

3.1 DESKRIPSI SOLUSI

Sketchbook Universe adalah simulasi interaktif berbasis web di mana siswa SMP menggambar objek menggunakan jari di depan kamera, kemudian sistem AI mengklasifikasikan gambar tersebut dan menampilkan tiga prediksi teratas beserta confidence score. Siswa kemudian membuat Keputusan menerima, mengoreksi, atau menolak melalui mekanisme Human-in-the-Loop (HITL). Setiap keputusan dicatat dan dianalisis untuk membaca pola perilaku siswa terhadap output AI.

Sistem menggunakan model CNN MobileNet V2 yang dikonversi ke TensorFlow.js sehingga inferensi berjalan sepenuhnya di browser siswa tanpa perlu server AI. Server hanya berfungsi sebagai penerima log interaksi yang disimpan ke SQLite dan dianalisis menggunakan K-Means clustering secara offline.

3.2 METODOLOGI PENELITIAN

Metodologi penelitian menjelaskan pendekatan, metode pengembangan, analisis masalah, teknik pengumpulan dan analisis data, serta metode pengujian yang digunakan dalam proyek ini. Pendekatan penelitian bersifat *mixed methods* dengan paradigma *Research and Development* (R&D). Metode pengembangan perangkat lunak mengikuti model *Waterfall SDLC* dengan lima tahap berurutan. Analisis masalah dilakukan menggunakan diagram Fishbone (Ishikawa) dengan pendekatan 6M untuk mengidentifikasi *root cause* dari *automation bias* pada siswa

SMP terhadap output AI. Pengumpulan data dilakukan melalui *behavioral log* sistem (yang dikirim ke backend penulis), akurasi model CNN via confusion matrix, dan kuesioner System Usability Scale (SUS) yang di-share dengan rekan. Analisis data menggunakan K-Means clustering untuk segmentasi pola perilaku siswa dan statistik deskriptif untuk akurasi model. Pengujian dilakukan dengan black-box testing, akurasi model (confusion matrix), dan SUS untuk dashboard admin.

3.2.1 Jenis Penelitian

Penelitian ini menggunakan pendekatan Research and Development (R&D) dengan mixed methods data kuantitatif berupa akurasi CNN dan metrik clustering, serta data kualitatif berupa interpretasi cluster perilaku siswa. Pengembangan sistem mengikuti metode Waterfall SDLC dengan tahapan: Analisis Kebutuhan, Perancangan, Implementasi, Integrasi dan Pengujian, serta Pemeliharaan.

3.2.2 Analisis Masalah

Analisis masalah dilakukan menggunakan diagram Fishbone (Ishikawa) dengan pendekatan 6M Man, Method, Machine, Material, Measurement, dan Environment untuk mengidentifikasi root cause dari permasalahan inti: automation bias pada siswa SMP terhadap output AI.

3.2.3 Teknik Pengumpulan dan Analisis Data

Pengumpulan data dilakukan melalui tiga teknik: (1) behavioral log via REST API yang dikirim dari frontend ke backend setelah setiap keputusan siswa; (2) evaluasi model CNN menggunakan confusion matrix pada test set (20% dataset) dengan target akurasi $\geq 85\%$; dan (3) System Usability Scale (SUS) untuk admin dashboard dengan target skor ≥ 68 .

Analisis data menggunakan K-Means clustering pada behavioral log dengan fitur utama: `accept_rate`, `override_rate`, `mean_latency_ms`, dan `confidence_gap_mean`. Jumlah cluster k ditentukan via elbow method dan

silhouette score (kandidat $k = 3-5$). Akurasi model dievaluasi menggunakan persamaan berikut.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

3.3 DESAIN SISTEM

Desain sistem menguraikan keputusan desain yang diambil berdasarkan prinsip-prinsip akademis dari Bab II dan hasil analisis Fishbone 6M. Setiap keputusan desain disertai dengan justifikasi teknis agar hubungan antara teori dan implementasi dapat ditelusuri secara eksplisit.

3.3.1 Pemilihan Model CNN

Pemilihan MobileNet V2 sebagai model klasifikasi didasarkan pada dua lapis pertimbangan: pengujian empiris komparatif dan kesesuaian arsitektural dengan batasan sistem. Pada lapis pertama, enam arsitektur CNN dilatih pada dataset Quick Draw! dengan kondisi yang setara (hyperparameter identik, dataset yang sama), kemudian dievaluasi pada 13 gambar tangan siswa. Evaluasi pada gambar tangan siswa dipilih secara sengaja—bukan test set standar—karena tujuannya adalah mengukur robustness model terhadap domain gap antara data latih (gambar Quick Draw! yang relatif konsisten) dan kondisi penggunaan nyata (gambar tangan siswa yang lebih bebas dan bervariasi). Kemampuan mengatasi domain gap inilah yang menjadi kriteria seleksi utama, bukan sekadar akurasi pada test set yang distribusinya sama dengan data latih. Tabel 3.1 merangkum hasil pengujian tersebut.

Tabel 3. 1 Perbandingan Akurasi Enam Model CNN pada Data Gambar Tangan Siswa

Model CNN	Akurasi pada Gambar Tangan Siswa
MobileNet V2	38%

Model CNN	Akurasi pada Gambar Tangan Siswa
EfficientNet-B0	31%
ResNet-18	23%
Custom CNN	15%
SqueezeNet	8%
SketchNN	0%

Berdasarkan Tabel 3.1, MobileNet V2 memberikan akurasi tertinggi (38%) dibandingkan lima model lain pada kondisi pengujian yang sama. Seluruh model menunjukkan domain gap, yaitu penurunan performa ketika model yang dilatih pada dataset Quick Draw! diuji pada gambar tangan siswa yang memiliki gaya menggambar lebih bebas dan tidak konsisten. Meskipun demikian, MobileNet V2 menunjukkan ketahanan (robustness) tertinggi terhadap domain gap tersebut.

Selain unggul dalam akurasi, MobileNet V2 dipilih karena tiga pertimbangan tambahan yang relevan dengan batasan arsitektural sistem. Pertama, ukuran model setelah dikonversi ke TensorFlow.js berada di bawah 5 MB, sehingga waktu unduh dan loading di browser siswa tetap cepat. Kedua, struktur depthwise separable convolution pada MobileNet V2 menghasilkan waktu inferensi 30-100 ms pada perangkat menengah, jauh lebih ringan dibanding ResNet-18 atau EfficientNet-B0 yang memiliki jumlah parameter lebih besar. Ketiga, MobileNet V2 memiliki dukungan konversi TensorFlow.js yang lebih matang dibandingkan arsitektur khusus sketsa seperti SketchNN, sehingga risiko kegagalan konversi maupun ketidaksesuaian operasi tensor lebih rendah.

Dengan demikian, MobileNet V2 dipilih bukan hanya karena unggul secara akurasi, tetapi juga karena paling sesuai dengan batasan masalah penelitian ini yang mensyaratkan inferensi sepenuhnya di sisi klien tanpa server kecerdasan buatan.

Pemilihan MobileNet V2 di atas MobileNet V3 (varian yang lebih baru) didukung pula oleh temuan eksternal. Wardhana dan Nugroho [30] membandingkan langsung MobileNet V2 dan MobileNet V3 pada tugas klasifikasi citra dengan kondisi pelatihan yang setara (epoch, optimizer, dan learning rate identik) dan menemukan bahwa MobileNet V2 mencapai akurasi rata-rata 99,33%,

jauh mengungguli MobileNet V3 yang hanya mencapai 42,97% pada dataset yang relatif kecil. Mereka mengaitkan penurunan performa MobileNet V3 dengan kompleksitas tambahan arsitekturnya berupa squeeze-and-excitation module dan fungsi aktivasi h-swish yang justru menyebabkan model lebih rentan mengalami overfitting ketika dilatih pada dataset berukuran kecil hingga menengah.

Temuan tersebut relevan dengan konteks penelitian ini karena dataset Quick Draw! yang digunakan, meskipun besar secara keseluruhan, dikurasi menjadi subset terbatas (116 kategori) yang dapat menimbulkan risiko serupa apabila menggunakan arsitektur dengan kompleksitas berlebih. Dengan demikian, pemilihan MobileNet V2 bukan semata-mata mengikuti versi yang lebih lama, melainkan didasarkan pada pertimbangan bahwa arsitektur yang lebih sederhana cenderung lebih stabil dan tidak mudah overfitting pada skala data yang digunakan dalam penelitian ini. Pola overfitting MobileNet V3 pada dataset kecil-menengah juga dikonfirmasi oleh Pushpanath et al. (2024) yang menguji ketiga model pada dataset klasifikasi terbatas dan menemukan pola serupa, di mana training accuracy V3 meningkat seiring epoch tetapi test accuracy tetap sangat rendah, mengindikasikan overfitting yang jelas [34]. Perbandingan resmi ketiga varian MobileNet berdasarkan benchmark ImageNet disajikan pada Tabel 3.2.

Tabel 3. 2 Perbandingan Resmi MobileNetV1, V2, dan V3 pada Benchmark ImageNet

Model	Top-1 Accuracy ImageNet	Parameter	FLOPs
MobileNetV1	70,6%	4,2 juta	569 juta
MobileNetV2	71,8%	3,4 juta	300 juta
MobileNetV3-Large	75,2%	5,4 juta	219 juta

Sumber: Howard et al. (2017) [32]; Sandler et al. (2018) [32]; Howard et al. (2019) [33].

Tabel 3. 3 Hasil Pengujian MobileNetV3 pada Dataset Kecil (Klasifikasi American Sign Language)

Epoch	Training Accuracy	Test Accuracy
5	27,66%	3,40%
10	33,69%	3,57%
20	34,92%	4,09%

Sumber: Pushpanath et al. (2024) [34].

Tabel 3.3 menunjukkan bahwa MobileNetV3 mengalami penurunan performa pada dataset American Sign Language yang digunakan oleh Pushpanath et al. [34]. Temuan tersebut memberikan gambaran bahwa performa MobileNetV3 dapat bervariasi bergantung pada karakteristik data dan proses pelatihannya. Di sisi lain, berdasarkan benchmark resmi ImageNet, MobileNetV3 tetap menunjukkan akurasi yang lebih tinggi dibandingkan MobileNetV2. Oleh karena itu, penelitian ini tidak menyimpulkan bahwa MobileNetV3 lebih rendah dari MobileNetV2, melainkan memilih MobileNetV2 karena menyediakan keseimbangan antara akurasi, efisiensi komputasi, serta dukungan implementasi yang matang pada ekosistem TensorFlow dan TensorFlow.js sesuai kebutuhan penelitian.

Sementara itu, MobileNetV1 tidak dipilih karena MobileNetV2 merupakan pengembangan resmi yang memperbaiki keterbatasan arsitektur sebelumnya melalui inverted residual blocks dan linear bottlenecks. Berdasarkan benchmark resmi, MobileNetV2 memiliki akurasi yang lebih tinggi, jumlah parameter lebih sedikit, serta kebutuhan komputasi yang lebih rendah dibandingkan MobileNetV1. Karakteristik tersebut menjadikan MobileNetV2 lebih efisien untuk deployment pada perangkat dengan sumber daya terbatas tanpa mengorbankan performa klasifikasi. Dengan demikian, MobileNetV2 dipilih sebagai backbone pada penelitian ini karena memberikan keseimbangan yang baik antara akurasi, efisiensi komputasi, dan kemudahan implementasi pada sistem berbasis TensorFlow.js.

Pemilihan Framework TensorFlow

Pelatihan model CNN dalam penelitian ini menggunakan framework TensorFlow beserta API tingkat tinggi Keras, bukan framework alternatif seperti PyTorch. Pemilihan ini didasarkan pada tiga pertimbangan utama yang berkaitan langsung dengan batasan arsitektural sistem yang mensyaratkan inferensi sepenuhnya di sisi klien (client-side).

Pertama, TensorFlow memiliki jalur konversi resmi dan dipelihara langsung oleh Google menuju TensorFlow.js melalui tool `tensorflowjs_converter`, sehingga model yang dilatih dalam format Keras (.h5 atau SavedModel) dapat dikonversi menjadi format model.json dan weight shards tanpa memerlukan konversi perantara. Sebaliknya, model yang dilatih menggunakan PyTorch memerlukan jalur konversi yang lebih panjang dan kurang stabil, umumnya melalui format ONNX terlebih dahulu sebelum dapat dijalankan di lingkungan JavaScript, yang berpotensi menimbulkan ketidaksesuaian operasi tensor (unsupported ops) pada arsitektur tertentu.

Kedua, TensorFlow menyediakan model MobileNet V2 pre-trained pada dataset ImageNet secara native melalui modul `tf.keras.applications`, sehingga pendekatan transfer learning dapat diimplementasikan tanpa perlu mengunduh maupun mengonversi bobot model dari sumber eksternal.

Ketiga, penggunaan satu ekosistem (TensorFlow untuk pelatihan dan TensorFlow.js untuk inferensi di browser) menjaga konsistensi application programming interface dan format data antara tahap pelatihan dan tahap deployment, sehingga mengurangi risiko kesalahan yang umum terjadi ketika model dipindahkan antar framework yang berbeda. Pertimbangan ini sejalan dengan kebutuhan utama penelitian, yaitu memastikan bahwa model klasifikasi dapat dijalankan secara langsung di sisi klien tanpa server kecerdasan buatan, sebagaimana telah dinyatakan pada batasan masalah penelitian ini.

Pemilihan TensorFlow juga didukung oleh bukti performa empiris yang relevan dengan karakteristik dataset yang digunakan. Yapıcı dan Topaloğlu [31] membandingkan performa lima framework deep learning (TensorFlow, Keras dengan backend TensorFlow, Theano, Keras dengan backend Theano, dan PyTorch) pada GPU menggunakan dua dataset dengan ukuran citra yang berbeda.

Pada dataset MNIST yang berukuran 28×28 piksel, TensorFlow secara konsisten menjadi framework tercepat untuk seluruh ukuran batch yang diuji (200, 100, dan 50 batch), baik dari segi batch time maupun epoch time. Sebaliknya, pada dataset GPDS Signature yang berukuran lebih besar (224×224 piksel), performa terbaik berpindah ke PyTorch karena manajemen memori yang lebih efisien, sementara TensorFlow bahkan mengalami galat kehabisan memori GPU (CUDA_ERROR_OUT_OF_MEMORY) pada beberapa ukuran batch.

Temuan tersebut relevan secara langsung dengan penelitian ini karena dataset Quick Draw! yang digunakan berformat citra 28×28 piksel, identik dengan kondisi MNIST yang diuji oleh Yapıcı dan Topaloğlu [31]. Dengan demikian, pemilihan TensorFlow tidak hanya didasarkan pada pertimbangan kemudahan konversi ke TensorFlow.js, tetapi juga didukung oleh bukti empiris bahwa TensorFlow memberikan performa pelatihan tercepat pada skala citra yang setara dengan yang digunakan dalam penelitian ini. Ringkasan hasil pengujian pada dataset MNIST disajikan pada Tabel 3.4.

Tabel 3. 4 Perbandingan Batch Time dan Epoch Time pada Dataset MNIST (28×28 piksel)


Framework	Batch Time (ms) 200 Batch	Epoch Time (ms) 200 Batch
TensorFlow	45	13.938
Keras (TensorFlow Backend)	59	16.650
PyTorch	78	21.680
Theano	343	85.387

Sumber: diolah dari Yapıcı dan Topaloğlu (2021), diukur pada GPU NVIDIA TITAN XP.

3.3.2 Desain Sistem Global

Sistem menggunakan arsitektur hybrid di mana inferensi AI berjalan di sisi klien (browser) menggunakan TensorFlow.js, sementara server hanya menangani

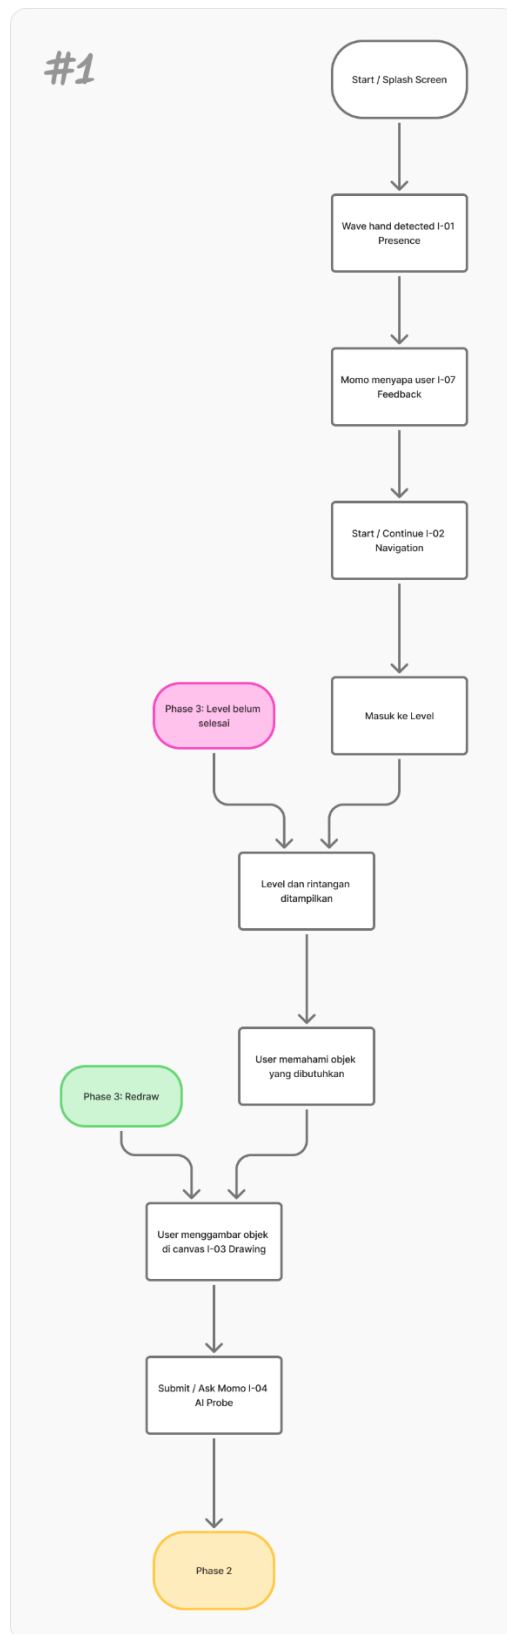
logging dan penyimpanan data. Gambaran umum sistem ditunjukkan pada Gambar 3.1.



Gambar 3. 1 Desain Sistem Global


3.3.3 User Flow

Alur penggunaan sistem oleh siswa dimulai dari login, menggambar objek di canvas, melihat hasil prediksi AI berupa Top-3 dan confidence score, mengambil keputusan Accept/Correct/Override melalui Probe UI, hingga gameplay berlanjut. Setiap keputusan dikirim ke backend sebagai log interaksi secara asynchronous. Gambar 3.2 menunjukkan user flow secara keseluruhan




Gambar 3. 2 Userflow Fase 1

#2




Gambar 3. 3 UserFlow Fase 2



Gambar 3. 4 UserFlow Fase 3

3.3.4 Use Case

Sistem memiliki tiga aktor: Siswa, Guru, dan Superadmin. Scope penulis mencakup seluruh backend dari use case tersebut, meliputi autentikasi, pencatatan log, validasi override (Top-6 Check), dashboard analitik, trigger K-Means, export data, dan manajemen entitas oleh superadmin. Gambar 3.3 menunjukkan use case diagram sistem.



Gambar 3. 5 Use Case

3.3.5 Alur Backend

Backend menangani dua alur utama. Pertama, alur logging (fire-and-forget): frontend mengirim POST `/api/logs/event` → backend validasi JWT dan payload →

INSERT ke SQLite → return 204 No Content. Kedua, alur Top-6 Check: frontend mengirim POST /probe/override beserta label pilihan siswa dan Top-6 dari CNN → backend melakukan case-insensitive match → return accepted: true (auto-accept) atau accepted: false (redraw). Gambar 3.4 menunjukkan kedua alur tersebut.

3.3.6 Perancangan K-Means Clustering

K-Means clustering digunakan untuk mengelompokkan siswa berdasarkan pola keputusan mereka terhadap output AI. Tujuannya bukan hanya deskriptif flat, tetapi menghasilkan segmentasi tipe pengambil keputusan yang bermakna secara akademis. Tabel 3.5 merinci fitur-fitur yang diekstrak per siswa sebagai input K-Means.

Tabel 3. 5 Feature Engineering untuk K-Means Clustering

Fitur	Rumus	Interpretasi
accept_rate	$\text{count}(\text{accept}) / \text{total_decisions}$	Tingkat kecenderungan menerima AI
correct_rate	$\text{count}(\text{correct}) / \text{total_decisions}$	Tingkat evaluasi alternatif
override_rate	$\text{count}(\text{override}) / \text{total_decisions}$	Tingkat penolakan AI
mean_latency_ms	$\text{mean}(\text{time_spent_ms})$	Rata-rata durasi keputusan
confidence_gap_mean	$\text{mean}(\text{conf_top1} - \text{conf_top2})$	Rata-rata ambiguitas prediksi
override_frequency	$\text{count}(\text{override}) / \text{total_probes}$	Frekuensi override per probe
top6_match_rate	$\text{count}(\text{top6_match}=\text{true}) / \text{count}(\text{override})$	Rasio override yang masuk akal (NEW post-pivot)
risk_acceptance_rate	$\text{count}(\text{accept pada conf } \leq 50\%) / \text{total_accept}$	Tingkat automation bias (Accept cepat pada conf rendah)
fail_rate	$\text{count}(\text{fail_level}) / \text{total_levels_played}$	Tingkat kegagalan level

3.3.7 Perancangan Technology Stack

Technology stack untuk scope penulis dipilih berdasarkan kebutuhan analisis, stabilitas, dan interoperabilitas. Tabel 3.6 merinci stack yang digunakan beserta alasannya.

Tabel 3. 6 Technology Stack

Komponen	Teknologi	Alasan
CNN Training	TensorFlow 2.x / Keras	Ekosistem matang, MobileNet V2 pre-trained tersedia, integrasi dengan TF.js converter
Model Export	tensorflowjs_converter	Konversi .h5 ke TF.js format (model.json + shard files)
Backend API	Node.js 18+ + Express 4.x	Ringan, async I/O, kompatibel dengan JSON, ekosistem npm matang
Database	SQLite 3.x	Tanpa konfigurasi server tambahan, cukup untuk skala riset, embedded
ORM	Sequelize 6.x	Konsistensi schema, migrasi, query builder
Authentication	JWT (jsonwebtoken)	Standar, stateless, mudah diimplementasi
Password Hashing	bcrypt	Standar industri untuk hashing password guru
Clustering	Python 3.10+ + scikit-learn 1.x	Implementasi K-Means matang, elbow method + silhouette score built-in
Data Processing	pandas 2.x + numpy	Feature engineering, normalisasi z-score, manipulasi matriks fitur
Dashboard Frontend	React 18 + Vite	Konsistensi dengan frontend rekan, komponen reusabel

Komponen	Teknologi	Alasan
Dashboard Charting	Chart.js atau Recharts	Visualisasi bar chart, scatter plot, line chart untuk dashboard guru

3.4 PEMBAGIAN TUGAS

Pengembangan proyek akhir ini dilakukan oleh dua orang dalam satu tim, yaitu penulis dan Farchan Deano Muhammad sebagai rekan kerja. Pembagian tugas disesuaikan dengan bidang keahlian masing-masing anggota. Penulis bertanggung jawab pada aspek Backend, REST API, Model CNN MobileNet, Penyimpanan Log SQLite, K-Means Clustering, Admin Dashboard, dan Kontrak Data. Rekan bertanggung jawab pada aspek Frontend, UI/UX, Probe UI, Animasi Momo, Level Design, Mekanisme HITL Top-6 Check, dan Wireframe. Tabel 3.7 merinci pembagian tugas per komponen tabel ini identik dengan yang ada pada Bab 3 rekan untuk memastikan konsistensi kedua proposal.

Tabel 3. 7 Pembagian Tugas per Komponen Sistem

Komponen Sistem	Scope (Rekan)	Scope (Penulis)
Login	UI Login Siswa (class_id + nomor_absen)	Backend endpoint POST /auth/login, JWT generation
Onboarding	Splash screen, Momo intro, Tutorial objek	-
Level Design	3 level (Trust Build, Ambiguity, Override)	-
Main Gameplay	Canvas, Kaplay.js loop, Stickman movement	-
Canvas Tools	Tombol Resize, Rotate, Eraser (UI)	-
Timer	Timer count-up display, time_spent_ms field	-
CNN Model	-	MobileNet V2 training, TF.js conversion

Komponen Sistem	Scope (Rekan)	Scope (Penulis)
AI Inference	Load TF.js model di browser, tampilkan Top-3	-
Probe UI	Tampilan Top-3, tombol Accept/Correct/Override	-
Top-6 Check	Kirim POST /probe/override	Backend Top-6 Check, return auto-accept/redraw
Momo Animation	State machine, 5 state, text bubble	-
Behavior Mapping	Solid/Danger mapping (frontend)	Label mapping table (shared)
Backend API	-	Node.js + Express, REST endpoints
Database	-	SQLite, schema interaction_logs
K-Means Clustering	-	Python + scikit-learn, feature engineering
Admin Dashboard	-	Dashboard guru (decision distribution, cluster)
Superadmin UI	-	Dashboard superadmin (school/class/guru management)
Data Logging	Pack event, kirim POST /logs/event	Backend validasi, INSERT ke SQLite
Integrasi Penulis-Rekan	Titik temu Probe UI + POST /logs/event	Titik temu Probe UI + POST /logs/event
Pengujian SUS	SUS ke siswa, behavioral log analysis	Akurasi model, dashboard testing

3.5 JADWAL PENELITIAN

Penelitian dilaksanakan selama 12 bulan mengikuti tahapan Waterfall SDLC. Tabel 3.8 menunjukkan jadwal kegiatan sinkron antara penulis dan rekan.

Tabel 3. 8 Jadwal Penelitian Sinkron 17 Kegiatan 12 Bulan

No	Kegiatan	Inisial	1	2	3	4	5	6	7	8	9	10	11	12
1	Studi Literatur & Pengumpulan Referensi	CD	X	X										
2	Penyusunan Proposal	CD		X	X	X								
3	Analisis Kebutuhan & Use Case (Fishbone 6M)	CD			X	X								
4	Desain Sistem Global (Waterfall)	CD				X	X							
5	Pengumpulan & Kurasi Dataset Quick Draw	D					X	X						
6	Pelatihan Model CNN MobileNet	D						X	X					
7	Konversi Model ke TensorFlow.js	D							X					
8	Pengembangan Frontend Kaplay.js + React	C					X	X	X	X				
9	Desain Maskot Momo (OPSI E Doodle Cube)	C						X	X					
10	Implementasi Level Design + HITL UI Top-6 Check	C							X	X	X			

No	Kegiatan	Inisial	1	2	3	4	5	6	7	8	9	10	11	12
11	Implementasi Backend REST API	D						X	X	X				
12	Implementasi Data Logging + SQLite	D								X	X			
13	Implementasi K-Means Clustering	D									X	X		
14	Implementasi Superadmin Dashboard	D									X	X		
15	Integrasi Penulis-Rekan (Kontrak Data)	CD										X	X	
16	Pengujian SUS + Black-Box	CD											X	X
17	Penulisan Laporan Akhir	CD											X	X

DAFTAR PUSTAKA

- [1] D. T. K. Ng, J. K. L. Leung, S. K. W. Chu, and M. S. Qiao, “Conceptualizing AI literacy: An exploratory review,” *Computers and Education: Artificial Intelligence*, vol. 2, p. 100041, 2021.
- [2] V. Casal-Otero et al., “AI literacy in K-12: A systematic literature review,” *International Journal of STEM Education*, vol. 10, p. 29, 2023.
- [3] H. Khosravi et al., “Explainable artificial intelligence in education,” *Computers and Education: Artificial Intelligence*, vol. 3, p. 100074, 2022.
- [4] E. Mosqueira-Rey, V. Alonso-Ríos, and B. Rubio-Ríos, “Human-in-the-loop machine learning: A state of the art,” *Artificial Intelligence Review*, vol. 56, no. 4, pp. 3005–3054, 2023.
- [5] B. Memarian and T. Doleck, “Human-in-the-loop in artificial intelligence in education: A review and entity-relationship (ER) analysis,” *Computers in Human Behavior: Artificial Humans*, vol. 2, p. 100053, 2024.
- [6] L. Xu et al., “Deep learning for free-hand sketch: A survey,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 45, no. 1, pp. 285–312, 2023.
- [7] G. Z. L. Goh, D. Ho, and Z. A. Abas, “Front-end deep learning web apps development and deployment: A review,” *Applied Intelligence*, vol. 53, pp. 15923–15945, 2023.
- [8] D. Smilkov et al., “TensorFlow.js: Machine learning for the web and beyond,” in *Proceedings of the 2nd SysML Conference*, 2019, pp. 1–10.
- [9] A. J. Karran, S. Demazure, and C. Hudelot, “Designing for confidence: The impact of visualizing artificial intelligence decisions,” *Frontiers in Neuroscience*, vol. 16, 2022.
- [10] P. Pansri et al., “Understanding student learning behavior through K-Means clustering,” *Education Sciences*, vol. 14, no. 12, p. 1291, 2024.

- [11] A. Alzahrani et al., “Identifying weekly student engagement patterns via K-Means clustering,” *Electronics*, vol. 14, no. 15, p. 3018, 2025.
- [12] M. Videnovik et al., “Game-based learning in computer science education: A scoping literature review,” *International Journal of STEM Education*, vol. 10, p. 54, 2023.
- [13] K. K. Chan, K. M. Wan, and R. B. King, “Performance over enjoyment? Effect of game-based learning on learning outcome and flow experience,” *Frontiers in Education*, vol. 6, p. 660376, 2021.
- [14] R. S. Pressman, *Software Engineering: A Practitioner’s Approach*, 8th ed. New York, NY, USA: McGraw-Hill, 2014.
- [15] I. Sommerville, *Software Engineering*, 10th ed. Harlow, U.K.: Pearson, 2015.
- [16] Sugiyono, *Metode Penelitian Kuantitatif, Kualitatif, dan R&D*. Bandung, Indonesia: Alfabeta, 2020.
- [17] J. W. Creswell, *Research Design: Qualitative, Quantitative, and Mixed Methods Approaches*, 4th ed. Thousand Oaks, CA, USA: Sage Publications, 2014.
- [18] K. Ishikawa, *Guide to Quality Control*, 2nd ed. Tokyo, Japan: Asian Productivity Organization, 1986.
- [19] J. Brooke, “SUS: A quick and dirty usability scale,” in *Usability Evaluation in Industry*. London, U.K.: Taylor & Francis, 1996, pp. 189–194.
- [20] A. Bangor, P. T. Kortum, and J. T. Miller, “An empirical evaluation of the System Usability Scale,” *International Journal of Human-Computer Interaction*, vol. 24, no. 6, pp. 574–594, 2008.
- [21] M. Yin, J. Wortman Vaughan, and H. Wallach, “Understanding the effect of accuracy on trust in machine learning models,” in *Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems*, 2019, pp. 1–12.
- [22] C. Batanero and R. Álvarez-Arroyo, “Teaching and learning of probability,” *ZDM – Mathematics Education*, vol. 56, pp. 5–17, 2023.

- [23] Z. Zhan, Y. Tong, X. Lan, and B. Zhong, “A systematic literature review of game-based learning in artificial intelligence education,” *Interactive Learning Environments*, vol. 32, no. 4, pp. 1189–1212, 2024.
- [24] Q. V. Liao, D. Gruen, and S. Miller, “Questioning the AI: Informing design practices for explainable AI user experiences,” in *Proceedings of the 2020 CHI Conference on Human Factors in Computing Systems*, 2020, pp. 1–15.
- [25] Y. Feldman-Maggor, M. Cukurova, C. Kent, R. Luckin, and M. Baur-Wolfson, “The impact of explainable AI on teachers’ trust and acceptance of AI EdTech recommendations,” *International Journal of Artificial Intelligence in Education*, vol. 35, no. 1, pp. 1–25, 2025.
- [26] V. T. Huynh, T. T. Nguyen, T. V. Nguyen, and M. T. Tran, “MobileNet-SA: Lightweight CNN with self-attention for sketch classification,” in *Pacific-Rim Symposium on Image and Video Technology (PSIVT)*, Cham, Switzerland: Springer, 2023, pp. 115–129.
- [27] L. Li, C. Zou, Y. Zheng, Q. Su, H. Fu, and C. L. Tai, “Sketch-R2CNN: An RNN-rasterization-CNN architecture for vector sketch recognition,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, no. 9, pp. 4671–4685, 2020.
- [28] Google Creative Lab, “Quick, Draw! The Data,” Google, 2017. [Online]. Available: <https://quickdraw.withgoogle.com/data>. [Accessed: Jul. 25, 2026].
- [29] F. Liu, M. Lu, and W. Zhang, “Comparative analysis of deep learning-based models in sketch recognition,” in *Proceedings of ICAIC 2024*. Paris, France: Atlantis Press, 2024.
- [30] S. F. D. Wardhana and A. Nugroho, “Perbandingan Arsitektur MobileNetV2 dan MobileNetV3 Dalam Klasifikasi Jenis Jeruk,” *Jurnal Ilmu Komputer dan Bisnis (JIKB)*, vol. 16, no. 1, pp. 25–34, 2025, doi: 10.47927/jikb.v16i1.916.

- [31] M. M. Yapıcı and N. Topaloğlu, “Performance comparison of deep learning frameworks,” *Computers and Informatics*, vol. 1, no. 1, pp. 1–11, 2021.
- [32] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, “MobileNetV2: Inverted Residuals and Linear Bottlenecks,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 4510–4520.
- [33] A. Howard et al., “Searching for MobileNetV3,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019, pp. 1314–1324.
- [34] Pushpanath M. R. et al., “A Comparative Analysis of EfficientNet and MobileNet Models’ Performance on Limited Datasets: An Example of American Sign Language Alphabet Detection,” *Highlights in Science, Engineering and Technology*, vol. 94, 2024.